#### Aprendizaje Reforzado

#### Maestría en Ciencia de Datos, DC - UBA

Julián Martínez Javier Kreiner

#### Repaso

Un paso de evalución, uno de mejora

Sarsa (on-policy)

Q-learning (off-policy)

$$Q^{k+1}(S,A) = Q^k(S,A) + \alpha(\mathbf{R}^+ + \gamma \mathbf{Q}^k(S^+, \mathbf{A}^+) - Q^k(S,A)),$$

 $Q^{k+1}(S,A) = Q^{k}(S,A) + \alpha(R^{+} + \gamma \max_{a'} Q^{k}(S^{+},a') - Q^{k}(S,A))$ 

con  $S^+$  proveniente de tomar la acción  $A^+$  con la política  $\pi_{k+1} = \varepsilon - greedy(Q^k)$ .

#### Aproximación de función de valor

$$J(w) := E_{\mu}[(v_{\pi}(S) - \hat{v}(S; w))^{2}] = \sum_{s \in S} \mu(s)(v_{\pi}(s) - \hat{v}(s; w))^{2},$$

En lugar de calcular  $v_{\pi}(s)$ ,  $\forall s$ , aproximamos globalmente controlando los parámetros w.

Recuerdo: Regresión Lineal

$$J(\beta) = E[(Y - f_{\beta}(X))^{2}] \approx \frac{1}{n} \sum_{i=1}^{n} (y_{i} - f_{\beta}(x_{i}))^{2}$$

El cual se puede minimizar realizando Descenso por Gradiente Estocástico (Batch)

#### Descenso por Gradiente Estocástico (SGD)

 $w^{k+1} = w^k + \Delta w^{k+1}$ 

- Reemplazar una esperanza por una realización
- Reemplazar la función por el target

$$\Delta w^{k+1} = \alpha(\mathbf{q_{\pi}(S_t, A_t)} - \hat{q}(S_t, A_t; w)) \nabla_w \hat{q}(S_t, A_t; w)$$

Sarsa- on-policy

$$\approx \alpha(R_{t+1} + \gamma q_{\pi}(S_{t+1}, A_{t+1}) - \hat{q}(S_t, A_t; w)) \nabla_w \hat{q}(S_t, A_t; w)$$

Q-learning- off-policy

$$\approx \alpha(R_{t+1} + \gamma \max_{a'} q_{\pi}(S_{t+1}, a') - \hat{q}(S_t, A_t; w)) \nabla_w \hat{q}(S_t, A_t; w)$$

Podemos usar la experiencia que tengamos en más de una pasada de SGD!

#### Episodic Semi-gradient Sarsa for Estimating $\hat{q} \approx q_*$

Input: a differentiable action-value function parameterization  $\hat{q}: \mathbb{S} \times \mathcal{A} \times \mathbb{R}^d \to \mathbb{R}$ 

Algorithm parameters: step size  $\alpha > 0$ , small  $\varepsilon > 0$ 

Initialize value-function weights  $\mathbf{w} \in \mathbb{R}^d$  arbitrarily (e.g.,  $\mathbf{w} = \mathbf{0}$ )

Loop for each episode:

 $S, A \leftarrow \text{initial state}$  and action of episode (e.g.,  $\varepsilon$ -greedy)

Loop for each step of episode:

Take action A, observe R, S'

If S' is terminal:

$$\mathbf{w} \leftarrow \mathbf{w} + \alpha [R - \hat{q}(S, A, \mathbf{w})] \nabla \hat{q}(S, A, \mathbf{w})$$

Go to next episode

Choose A' as a function of  $\hat{q}(S', \cdot, \mathbf{w})$  (e.g.,  $\varepsilon$ -greedy)


$$\mathbf{w} \leftarrow \mathbf{w} + \alpha [R + \gamma \hat{q}(S', A', \mathbf{w}) - \hat{q}(S, A, \mathbf{w})] \nabla \hat{q}(S, A, \mathbf{w})$$

$$S \leftarrow S'$$

$$A \leftarrow A'$$

## **Policy Gradient**

Optimizamos directamente sobre la política.




# Modelizamos $\pi(a|s,\theta)$ como una distribución parametrizada por $\theta$ .

Recordar: Regresión Logística

- Puede aproximar más rápidamente una política determinística.
- En algunos contextos, la política óptima puede no ser determinística.


#### **Aliased Gridworld**

- Los sitios grises tienen iguales condiciones.
- Supongamos que sólo tengo información parcial del ambiente.




$$\phi(s, a) = \mathbf{1}(\text{wall to N}, a = \text{move E})$$

Aproximando la función de estado-acción (determinística)



Aproximando la política (estocástica)



### Diferentes posibilidades

$$\pi(a|s, \boldsymbol{\theta}) \doteq \frac{e^{h(s, a, \boldsymbol{\theta})}}{\sum_{b} e^{h(s, b, \boldsymbol{\theta})}}, \qquad h(s, a, \boldsymbol{\theta}) = \boldsymbol{\theta}^{\top} \mathbf{x}(s, a),$$

$$h(s, a, \boldsymbol{\theta}) = \boldsymbol{\theta}^{\top} \mathbf{x}(s, a),$$
 Softmax

$$\pi(a|s, \pmb{\theta}) \doteq \frac{1}{\sigma(s, \pmb{\theta}) \sqrt{2\pi}} \exp\left(-\frac{(a - \mu(s, \pmb{\theta}))^2}{2\sigma(s, \pmb{\theta})^2}\right)^{\text{Gaussianas (acciones continuas)}},$$

# **Funciones objetivo**

Tareas episódicas:

Tareas continuas:

$$J_{avV}(\theta) = \sum_{s} d^{\pi_{\theta}}(s) v_{\pi_{\theta}}(s),$$

 $J_0(\theta) = v_{\pi_{\theta}}(s_0),$ 

$$J_{avR}( heta)=\sum_s d^{\pi_ heta}(s)\sum_a \pi_ heta(s,a)\mathcal{R}^a_s,$$
 con  $d^{\pi_ heta}$  la distribución invariante de  $S_t|A_0,\ldots,A_{t-1}$ .

# Policy Gradient Theorem - Caso simple

$$J(\theta) = \sum_{s} d(s) E_{\pi_{\theta}}[R_1|S_0 = s] = \sum_{s} d(s) \sum_{a} \pi_{\theta}(s, a) \mathcal{R}_s^a,$$

$$S$$
  $S$   $A$   $\nabla_{ heta}\pi_{ heta}(s,a) = \pi_{ heta}(s,a) rac{\nabla_{ heta}\pi_{ heta}(s,a)}{\pi_{ heta}(s,a)} = \pi_{ heta}(s,a) rac{\nabla_{ heta}\pi_{ heta}(s,a)}{\pi_{ heta$ 

$$= \sum_{s}^{s} d(s) \sum_{a}^{s} \pi_{\theta}(s, a) \nabla \log \pi_{\theta}(s, a) \mathcal{R}_{s}^{a},$$

$$= \sum_{s}^{s} d(s) E_{\pi_{\theta}} [\nabla \log \pi_{\theta}(S_{0}, A_{0}) R_{1} | S_{0} = s].$$

#### **Policy Gradient Theorem**

$$J(\theta) = E_d[E_{\pi_{\theta}}[q_{\pi_{\theta}}(S_0, A_0)|S_0]],$$

#### entonces

$$\nabla_{\theta} J(\theta) = E_d[E_{\pi_{\theta}}[\nabla_{\theta} \log \pi_{\theta}(S_0, A_0) q_{\pi_{\theta}}(S_0, A_0) | S_0]],$$

Me da una expresión explícita para calcular el gradiente en términos de los ingredientes que sí puedo aproximar!

## Ejemplos de función score

$$\pi_{ heta}(s,a) \propto e^{\phi(s,a)^{ op} heta}$$

$$abla_{ heta} \log \pi_{ heta}(s, a) = \phi(s, a) - \mathbb{E}_{\pi_{ heta}} \left[\phi(s, \cdot)
ight]$$

$$\pi(a|s, \boldsymbol{\theta}) \doteq \frac{1}{\sigma(s, \boldsymbol{\theta})\sqrt{2\pi}} \exp\left(-\frac{(a - \mu(s, \boldsymbol{\theta}))^2}{2\sigma(s, \boldsymbol{\theta})^2}\right),$$

$$\nabla_{\theta} \log \pi_{\theta}(s, a) = \frac{(a - \mu(s))\phi(s)}{\sigma^2}$$

#### **REINFORCE - MC Policy Gradient**

#### REINFORCE: Monte-Carlo Policy-Gradient Control (episodic) for $\pi_*$

Input: a differentiable policy parameterization  $\pi(a|s, \theta)$ 

Algorithm parameter: step size  $\alpha > 0$ 

Initialize policy parameter  $\boldsymbol{\theta} \in \mathbb{R}^{d'}$  (e.g., to 0)

Loop forever (for each episode):

Generate an episode  $S_0, A_0, R_1, \ldots, S_{T-1}, A_{T-1}, R_T$ , following  $\pi(\cdot|\cdot, \boldsymbol{\theta})$ 

Loop for each step of the episode t = 0, 1, ..., T - 1:

$$G \leftarrow \sum_{k=t+1}^{T} \gamma^{k-t-1} R_k \tag{G_t}$$

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha \gamma^t G \nabla \ln \pi (A_t | S_t, \boldsymbol{\theta})$$

#### Algoritmo Actor-Crítico

MC Policy Gradient tiene mucha varianza. ¿Cómo reducirla?

crítico: Evalua la política.

$$\hat{q}(s, a; w) \approx q_{\pi_0}(s, a)$$

actor: Actualiza los parámetros de la política siguiendo las sugerencias del crítico.

$$\Delta \theta^{k+1} = \alpha \nabla_{\theta^k} \log \pi_{\theta^k}(s, a) \hat{q}(s, a; w)$$

- Simple actor-critic algorithm based on action-value critic

Using linear value fn approx. 
$$Q_w(s, a) = \phi(s, a)^\top w$$
  
Critic Updates  $w$  by linear TD(0)

Actor Updates  $\theta$  by policy gradient

#### function QAC

Initialise s.  $\theta$ Sample  $a \sim \pi_{\theta}$ 

for each step do Sample reward  $r = \mathcal{R}_s^a$ ; sample transition  $s' \sim \mathcal{P}_{s..}^a$ 

$$\delta = r + \gamma Q_w(s', a') - Q_w(s, a)$$
 $\theta = \theta + \alpha \nabla_{\theta} \log \pi_{\theta}(s, a) Q_w(s, a)$ 
 $w \leftarrow w + \beta \delta \phi(s, a)$ 

Sample action  $a' \sim \pi_{\theta}(s', a')$ 

end for

end function

 $a \leftarrow a', s \leftarrow s'$ 

### Sesgo en Actor-Crítico

$$\hat{q}(s, a; w) \approx q_{\pi_0}(s, a)$$

Introduce un sesgo en el gradiente. ¿Cómo controlar cuánto afecta en la actualización de la política?

$$abla_w Q_w(s,a) = \overline{\nabla_{ heta} \log \pi_{ heta}(s,a)}$$
 Compatible

Minimiza el EM

 $\mathbb{E}_{\pi_{\theta}}\left[\left(Q^{\pi_{\theta}}(s,a)-Q_{w}(s,a)\right)^{2}\right]$ 

El gradiente es exacto

$$\nabla_{ heta} J( heta) = \mathbb{E}_{\pi_{ heta}} \left[ \nabla_{ heta} \log \pi_{ heta}(s, a) \; Q_w(s, a) 
ight]$$

# Reduciendo la varianza de MC Policy Gradient

$$\mathbb{E}_{\pi_{ heta}}\left[
abla_{ heta}\log\pi_{ heta}(s,a)B(s)
ight] = \sum_{s\in\mathcal{S}}d^{\pi_{ heta}}(s)\sum_{ extbf{a}}
abla_{ heta}\pi_{ heta}(s,a)B(s)$$

 $\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi_{\theta}} \left[ \nabla_{\theta} \log \pi_{\theta}(s, a) A^{\pi_{\theta}}(s, a) \right]$ 

$$B(s) = V^{\pi_{ heta}}(s)$$
  $= \sum_{s \in \mathcal{S}} d^{\pi_{ heta}} B(s) 
abla_{a \in \mathcal{A}} \sum_{a \in \mathcal{A}} \pi_{ heta}(s, a)$   $= 0$ 
Restarle una Baseline puede reducir la varianza **sin**  $A^{\pi_{ heta}}(s, a) = Q^{\pi_{ heta}}(s, a) - V^{\pi_{ heta}}(s)$ 

modificar el

gradiente.

# Más parámetros...

 $V_{\nu}(s) \approx V^{\pi_{\theta}}(s)$ 

Actualizar las dos funciones de valor usando TD

 $Q_w(s,a) \approx Q^{\pi_{\theta}}(s,a)$ 

 $A(s,a) = Q_w(s,a) - V_v(s)$ Función de Ventaja

Otra posibilidad  $A^{\pi_{\theta}}(s,a) \approx r^+ + \gamma V^{\pi_{\theta}}(s^+) - V^{\pi_{\theta}}(s)$ 

 $\approx r^+ + \gamma V_v(s^+) - V_v(s)$ 

For the true value function  $V^{\pi_{\theta}}(s)$ , the TD error  $\delta^{\pi_{\theta}}$   $\delta^{\pi_{\theta}} = r + \gamma V^{\pi_{\theta}}(s') - V^{\pi_{\theta}}(s)$ 

$$egin{aligned} \mathbb{E}_{\pi_{ heta}}\left[\delta^{\pi_{ heta}}|s,a
ight] &= \mathbb{E}_{\pi_{ heta}}\left[r+\gamma V^{\pi_{ heta}}(s')|s,a
ight] - V^{\pi_{ heta}}(s) \ &= Q^{\pi_{ heta}}(s,a) - V^{\pi_{ heta}}(s) \ &= A^{\pi_{ heta}}(s,a) \end{aligned}$$

■ So we can use the TD error to compute the policy gradient

$$abla_{ heta} J( heta) = \mathbb{E}_{\pi_{ heta}} \left[ 
abla_{ heta} \log \pi_{ heta}(s, a) \; \delta^{\pi_{ heta}} 
ight]$$

■ In practice we can use an approximate TD error

$$\delta_{\mathsf{v}} = r + \gamma V_{\mathsf{v}}(s') - V_{\mathsf{v}}(s)$$

■ This approach only requires one set of critic parameters *v*